

Computação em Nuvem

Elasticidade e Escalabilidade

1.4

Fundamentos de Computação em Nuvem

Elasticidade e Escalabilidade

01

Conceito de elasticidade e como os recursos podem ser dimensionados automaticamente para atender à demanda

02

Aprender sobre os diferentes métodos de escalabilidade (horizontal e vertical)

03

Saber como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

Elasticidade

- A elasticidade é a capacidade de um sistema ou aplicação ajustar dinamicamente seus recursos de computação de acordo com as demandas variáveis da carga de trabalho.
- Envolve a capacidade de escalar para cima (aumentar recursos) ou para baixo (diminuir recursos) conforme necessário, permitindo que o sistema mantenha o desempenho e a eficiência operacional sob condições de demanda flutuante.

Elasticidade

- Os Recursos podem ser dimensionados automaticamente;
- Máquinas Virtuais (VMs) e Contêineres;
- Autoescalonamento automático;
- Balanceamento de Carga;
- Políticas de Dimensionamento Automático;
- Funções de Serviço sem Estado (Serverless);
- Redimensionamento Dinâmico de Armazenamento;
- Monitoramento em Tempo Real.

Escalabilidade (Horizontal e Vertical)

- A escalabilidade pode ser alcançada de duas maneiras principais: escalabilidade horizontal e escalabilidade vertical.
- Cada método tem suas características distintas e é aplicado em diferentes cenários, dependendo das necessidades específicas do sistema.

Escalabilidade Horizontal

- A escalabilidade horizontal envolve adicionar mais instâncias idênticas (máquinas virtuais, contêineres, servidores) ao sistema para distribuir a carga de trabalho.
- Exemplo: Se um aplicativo web está experimentando um aumento repentino no tráfego, mais instâncias de servidores web podem ser provisionadas automaticamente para lidar com a carga adicional.

Escalabilidade Horizontal

- ✓ Distribuição de Carga: A carga é distribuída entre várias instâncias, permitindo uma melhor distribuição do tráfego e evitando gargalos em uma única máquina.
- ✓ Facilidade de Adição/Remoção: Novas instâncias podem ser adicionadas ou removidas conforme necessário, proporcionando flexibilidade dinâmica.
- ✓ Escalabilidade Horizontal na Nuvem: Ambientes de nuvem são particularmente adequados para escalabilidade horizontal, permitindo adicionar ou remover recursos conforme a demanda.

Escalabilidade Horizontal

- ✓ Aumento de Recursos: Adição de CPU, memória, armazenamento ou outros recursos a uma máquina existente para atender às demandas crescentes.
- ✓ Complexidade e Downtime: Pode envolver períodos de inatividade e é geralmente mais complexa do que a escalabilidade horizontal.
- ✓ Limites Físicos: Existe um limite para o quanto uma única máquina pode ser escalada verticalmente devido a limitações físicas.

Escalabilidade Vertical

- A escalabilidade vertical envolve aumentar ou diminuir a capacidade de uma única instância, adicionando mais recursos à mesma máquina.
- Exemplo: Se um banco de dados em um servidor único está sobrecarregado, pode-se escalá-lo verticalmente adicionando mais CPU ou RAM à mesma máquina para melhorar o desempenho.

Escalabilidade Vertical

- Características:

- Aumento de Recursos: Adição de CPU, memória, armazenamento ou outros recursos a uma máquina existente para atender às demandas crescentes.
- Complexidade e Downtime: Pode envolver períodos de inatividade e é geralmente mais complexa do que a escalabilidade horizontal.
- Limites Físicos: Existe um limite para o quanto uma única máquina pode ser escalada verticalmente devido a limitações físicas.

Como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

- Elasticidade e escalabilidade permitem a otimização do uso de recursos e na redução de custos na computação em nuvem.
- Ambos permitem que as organizações ajustem dinamicamente seus ambientes de TI para atender à demanda flutuante, resultando em eficiência operacional e financeira.

Como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

- Algumas maneiras pelas quais essas capacidades contribuem para a otimização de recursos e redução de custos:
- Uso Eficiente de Recursos:
 - Elasticidade: Permite a alocação dinâmica e automática de recursos conforme a demanda, evitando subutilização durante períodos de baixa demanda e provisionando automaticamente mais recursos quando necessário.
 - Escalabilidade: Permite adicionar ou remover recursos de maneira eficiente, distribuindo a carga de trabalho de maneira equitativa entre instâncias ou ajustando verticalmente as instâncias conforme a necessidade.

Como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

- Pagamento por uso:
 - Resposta Dinâmica Elasticidade: Os modelos de elasticidade geralmente são baseados em pagamento por uso, onde os recursos consumidos são proporcionais à demanda real. Isso evita gastos desnecessários em recursos não utilizados.
 - Escalabilidade: A escalabilidade permite ajustar os recursos de acordo com as necessidades específicas, evitando a necessidade de investimentos antecipados em infraestrutura que podem não ser totalmente utilizados.
- Mudanças de Carga:
 - Elasticidade: A resposta automática às mudanças na carga de trabalho garante que os recursos estejam sempre alinhados com a demanda real, otimizando a eficiência operacional.
 - Escalabilidade: Permite que os sistemas respondam proativamente a picos de tráfego, garantindo que os recursos estejam disponíveis quando necessário e evitando interrupções ou degradação de desempenho.

Como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

- Redução de Custos Operacionais
 - Elasticidade: Ao ajustar dinamicamente os recursos, as operações manuais de provisionamento e desaprovisionamento são reduzidas, resultando em menor carga operacional e menor probabilidade de erros humanos.
 - Escalabilidade: A automação e a capacidade de escalonamento horizontal reduzem a necessidade de intervenção manual, tornando as operações mais eficientes.
- Otimização de Infraestrutura Subutilizada:
 - Elasticidade: Evita a subutilização de recursos durante períodos de baixa demanda, garantindo que apenas os recursos necessários estejam em operação.
 - Escalabilidade: Permite a expansão ou redução rápida e eficiente de recursos, otimizando a infraestrutura para atender às necessidades atuais.

Como a elasticidade e a escalabilidade contribuem para a otimização do uso de recursos e a redução de custos

- Flexibilidade e Auto-scaling:
 - Elasticidade: Proporciona flexibilidade para adaptar rapidamente os recursos à medida que os requisitos do negócio mudam.
 - Escalabilidade: Oferece agilidade na expansão ou contratação de recursos, permitindo que as organizações respondam rapidamente às mudanças nas condições do mercado.